

**RAMA ESTUDIANTIL IEEE EMBS – CONGRESO CONTEC**

**MEDDATA CHALLENGE**  
**“TRANSFORMANDO DATOS MÉDICOS EN SOLUCIONES INTELIGENTES”**

**SISTEMA DE PUNTUACIÓN DE RIESGO DE DIABETES**

**DOCUMENTACIÓN DEL PROYECTO:**  
**METODOLOGÍA, RESULTADOS, VISUALIZACIONES E IMPACTO**

**INTEGRANTES DEL EQUIPO:**

|                 |             |
|-----------------|-------------|
| CORNELIO GUERRA | 4-826-268   |
| JESÚS GUERRA    | 8-1035-1354 |

**REPOSITORIO:**

[github.com/Cornelio-Guerra/datathon-meddata](https://github.com/Cornelio-Guerra/datathon-meddata)

**FECHA:**

04 DE SEPTIEMBRE DEL 2026

**1. EL PROBLEMA**

El sistema de salud necesita detectar patrones de diabetes en miles de registros y decidir a quién derivar primero a prueba confirmatoria, cuando los recursos diagnósticos son limitados. Se trabajó sobre BRFSS 2015: 253,680 encuestas con 22 variables.

**2. METODOLOGÍA**

**2.1 Depuración e inconsistencias**

| Hallazgo                                   | Registros     | Decisión                                                    |
|--------------------------------------------|---------------|-------------------------------------------------------------|
| Duplicados exactos                         | 23,899 (9.4%) | Eliminados — se reporta también el escenario contrario      |
| IMC fuera de rango fisiológico (<12 o >60) | 805           | Eliminados — error de captura                               |
| Sin seguro y sin barrera de costo          | 7,838         | Conservados — no es contradicción: 63% de los no asegurados |
| Clase prediabetes                          | 4,612         | Excluida del ajuste — estado intermedio con pocos casos     |

Población: **253,680 crudos** → **228,976 depurados** → **224,364 calibrados**.

**2.2 Construcción del score — método de Sullivan (Framingham)**

Para cada factor se calcula su odds ratio crudo contra un nivel de referencia y se convierte a puntos enteros:

$$\text{puntos} = \text{round}(\ln(\text{OR}) / B) \quad \text{con } B = 0.7532$$

donde B es el menor  $\ln(\text{OR})$  positivo observado. No hay pesos elegidos a mano ni ajustados por ensayo y error: cada punto multiplica los odds por  $\approx 1.45$ .

**2.3 ¿Por qué entra cada variable?**

| Variable                | Relación clínica                       | OR   |
|-------------------------|----------------------------------------|------|
| Salud autopercebida     | Marcador integrado de comorbilidad     | 18.8 |
| Edad                    | Deterioro de la función pancreática    | 8.7  |
| IMC                     | Principal factor modificable           | 6.0  |
| Presión alta            | Componente del síndrome metabólico     | 4.6  |
| Dificultad para caminar | Proxy de complicaciones                | 3.4  |
| Enfermedad cardíaca     | Comorbilidad del síndrome metabólico   | 3.3  |
| Colesterol alto         | Componente del síndrome metabólico     | 3.1  |
| Derrame previo          | Consecuencia vascular compartida       | 2.8  |
| Actividad física        | Protector — sensibilidad a la insulina | 0.55 |
| Consumo alto de alcohol | Protector aparente — ver limitaciones  | 0.33 |

Se descartó Cholesterol pese a estar entre los OR más altos: mide si la persona se hizo un chequeo, no su estado de salud. Es un marcador de contacto con el sistema sanitario, no un factor de riesgo.

## 2.4 ¿Por qué el corte en 7?

Se evaluaron 12 umbrales. El 7 no maximiza el accuracy: se eligió por el costo asimétrico del error. En tamizaje, un falso negativo es un paciente que se va sin diagnóstico; un falso positivo solo genera una prueba confirmatoria barata.

## 3. RESULTADOS

|  |  |  |  |
|--|--|--|--|
|  |  |  |  |
|--|--|--|--|

| Nivel    | Score | Pacientes | Prevalencia |
|----------|-------|-----------|-------------|
| Bajo     | ≤ 6   | 115,913   | 4.4%        |
| Moderado | 7–9   | 56,450    | 17.9%       |
| Alto     | 10–12 | 36,137    | 33.1%       |
| Muy alto | ≥ 13  | 15,864    | 49.2%       |

El AUC se calculó con el estadístico de **Mann-Whitney implementado a mano**, sin librerías de machine learning, y coincide con la implementación de referencia.

### 3.1 Clasificación de un paciente nuevo

Ejemplo — 60-64 años, IMC 33, salud regular, hipertensión, colesterol alto:

IMC 2 + Edad 2 + Salud 3 + Hipertensión 2 + Colesterol 2 = **11 puntos** → **Alto** → **33.1%** → **derivar SÍ**

El sistema se aplica **en papel, sin computadora y sin laboratorio**.

## 4. VISUALIZACIONES

*El score separa 11 veces entre el grupo de menor y mayor riesgo.*

*Salud autopercebida y edad pesan más que los marcadores clínicos.*

*Distribución del score — se deriva al 48.3% de mayor puntaje (corte ≥ 7).*

## 5. HALLAZGOS

- **La limpieza de datos es una decisión, no un trámite — y la medimos en ambas direcciones.** Verificamos si los 23,899 duplicados eran errores de captura o colisiones de azar: tienen 1.0% de diabetes contra 15.3% del resto y cero derrames — el perfil joven-sano modal, firma de una colisión estadística en una encuesta de 21 variables casi todas binarias. Corrimos el pipeline en ambos escenarios: sin deduplicar AUC 0.816; deduplicando, 0.798. Reportamos la cifra conservadora.
- **La salud autopercebida predice mejor que varios marcadores clínicos.** Quien califica su salud como “mala” tiene 38.9% de diabetes contra 3.3% de quien la califica “excelente” — un OR de 18.8, el más alto de los 10 factores del score, por encima de presión alta (4.6) y colesterol (3.1). Es una pregunta que cuesta cero y ordena mejor que un análisis de sangre.
- **Diez preguntas estratifican el riesgo 11 veces, sin laboratorio.** Derivando al 48% de mayor puntaje se captura el 85.5% de los diabéticos, y cuando el sistema dice “bajo riesgo” acierta el 95.6% de las veces.

## 6. IMPACTO POTENCIAL

- **Tamizaje sin costo marginal.** Diez preguntas de entrevista, sin laboratorio ni equipo.
- **Priorización de lista de espera.** Derivar al 48% de mayor puntaje captura el 85.5% de los casos.
- **Descarte confiable.** Un VPN de 95.6% permite no consumir recursos diagnósticos en media población.
- **Auditable.** Cada punto se remonta a un odds ratio calculado sobre datos públicos.

### Sobre el uso de machine learning

Los organizadores confirmaron que el ML está permitido. Se usó solo como contraste: un Random Forest sobre el dataset crudo alcanza AUC 0.823 frente a 0.798 del score. Esos 25 milésimos cuestan un modelo que nadie aplica en papel ni audita — y ese 0.823 está medido sobre datos sin deduplicar. No son comparables.

## 7. LIMITACIONES DECLARADAS

- Datos autorreportados (encuesta telefónica).
- Odds ratio crudos, no ajustados por confusores: factores correlacionados aportan puntos de forma parcialmente redundante.
- El score se calibró y validó sobre el mismo conjunto.
- Se excluyó la prediabetes (1.8%) por insuficiencia de casos.
- El efecto protector del alcohol es casi con certeza confusión, no causalidad.

## 8. USO DE INTELIGENCIA ARTIFICIAL

Conforme al reglamento, se declara en USO\_DE\_IA.md del repositorio: herramientas empleadas (Claude Opus 5 vía Claude Code y Codex), qué produjo cada una, qué decidió el equipo y los prompts principales textuales.

## **9. REPRODUCIBILIDAD**

```
pip install -r requirements.txt  
python src/score_diabetes.py
```

Ese comando reproduce íntegramente las cifras de este documento.